DX 時代における「信頼」の最適配置モデル
～コンテンツベース型と協調フィルタリング型での AI・店員の比較実験～

早稲田大学守口ゼミナール　20 期

稲邉晴香

DX 時代における「信頼」の最適配置モデル

～コンテンツベース型と協調フィルタリング型での AI・店員の比較実験～

Ⅰ――序論

1. 研究背景
2. 研究意義

Ⅱ――既存研究

1. レコメンドに関する既存研究
2. 「信頼」に関する既存研究
3. 「レコメンド手法」に関する既存研究
4. 既存研究まとめ
5. 現状分析
6. 問題提起

Ⅲ――Study1

1. 仮説設定
2. 調査前提
   （1）分析方法
   （2）商材選定
   （3）プレ調査
   （4）実験の状況設定
3. 本調査
   （1）調査概要
   （2）検証結果
   （3）考察

Ⅳ――Study2

1. 調査方法
2. 仮説設定
3. 検証結果
4. 考察

Ⅴ――Study3

1. 調査方法
2. プレ調査

（1）要因抽出
（2）探索的因子分析
3. 仮説設定
4. 本調査
（1）調査概要
（2）分析結果
5. 考察

Ⅶ──おわりに
1. まとめ
2. 本研究における限界と今後の課題

謝辞

参考文献
補録──実験概要、分析

Ⅰ――序論

1. 研究背景

現在、EC サイトのリコメンドエンジンに加え、実店舗においてもデジタルサイネージや AI アバターを用いた「AI 店員」による接客自動化が進んでいる。これにより消費者は膨大な商品の中から効率的に商品選択を行うことが可能となった。

具体的には大手コンビニエンスストアチェーンにおけるアバター店員の導入やアパレル店舗におけるスマートミラーの設置などが挙げられる。図表 1 のように例えばローソンでは 2023 年よりモニター上のアバターを通じて遠隔地のオペレーターや AI が接客を行う取り組みを開始し、人手不足の解消と新たな顧客体験の提供を模索している。また、GU などのアパレル店舗では顧客が手に取った商品に合わせたスタイリングをサイネージ上に即座に提案するシステムが実用化されている（図表 1）。このように、従来は人間の店員が行なっていた「商品の推奨」や「相談」といった対人コミュニケーションの領域にまで AI が急速に進出しつつある。

■図表―――1

アバター店員接客イメージ



（出典：株式会社ローソンホームページより引用）

しかし、こうした技術導入が進む一方で依然として「AI のレコメンドよりも人間の店員のレコメンドを信頼する」という消費者は少なくない。システムが刷新され、ハードウェアとしての AI 店員が店舗に設置されたとしても、顧客がその推奨内容を心理的に需要し、信頼しなければ DX 投資の効果は限定的なものとなる。実際に選択肢の絞り込みプロセスに着目して AI と店員のレコメンドの比較を行った田中・高橋・丸山・稲邉・松崎[2024]の研究では「考慮段階では AI レコメンドの方が店員レコメンドに比べて消費者の満足度に正の影響を与えており、選択段階では店員レコメンドの方が AI レコメンドに比べて満足度に正の影響を与えることが分かった」としている。そして、選択段階にて店員のレコメンドが AI のレコメンドよりも影響を与えた要因として、「寄り添い因子」「交流因子」「信頼因子」を挙げており、中でも「寄り添い因子」「交流因子」が「信頼因子」を媒介してより強い影響を与えていることを導き出

した。また、影響を与えた因子をAIにも適用させるために人間の店員に求める信頼感をAIにも直接反映させることで満足度の向上を図ることとしていた。そこで本研究では、あえて人間の後押しが効果的とされる選択段階のみに焦点を当て、信頼を構成する二要素をそれぞれのレコメンド手法に当てはめて選択段階でもAIが優位となる組み合わせがあるかを検討する。

2. 研究意義

(1)　学術的意義

従来では、異なる分野として扱われてきた水晶アルゴリズムをMcAllister[1995]の対人信頼理論と接続し、その適合性を明らかにした点に新規性がある。分析の結果、推薦根拠は推薦主体に依存するという知見を提供するものであった。また、本研究では店員が論理的訴求と情緒的訴求の両方で一定の説得力を持っていた一方でAIは論理的訴求に特化していることを統計的に示した。特に製品関与度の低い消費者において特定の条件で評価低下を確認したため、重要な示唆を与えうる。

Study2では製品関与度を要因として追加したことで消費者行動論において精緻化見込みモデル理論が説明変数として強力であることも確認できる。

(2)　実務的意義

本研究においてAIと店員をどちらかを選ぶのではなくそれぞれの得意分野に分業することが最適であることがわかった。これにより消費者の購買意向や顧客満足度を損なうことなく付加価値の最大化を見込める。また、AIの発する内容に関しても新たな示唆を得ることができた。特にライト層をターゲットとする際は逆効果となるリスクが高い。よって正確で客観的な情報提供者としてのブランディングを徹底するのが効果的であると考えられる。

Study2の結果から、Webサイトやアプリにおいてマニア層に対しては詳細なスペック比較機能を前面にだし、ライト層においては人間的要素を強調したコンテンツへと誘導することでコンバージョン率の向上が期待できると明らかにした点に本研究の実務的意義がある。

Ⅱ―――既存研究

研究を進めるにあたって、まずは関連する既存研究の整理を行う。

1.　「レコメンド」に関する既存研究

前章で述べたように、EC サイト上でのレコメンドに関する研究は数多く存在する。生田目・大竹・加藤［2020］は、「レコメンデーションとは、対象者（顧客）の属性情報や行動履歴に基づき、対象者の求める商品を推薦する（レコメンド）ことを指す。」と述べており、「レコメンドの効果としては、コンバージョン率（CV 率）や関心度の向上が考えられ、顧客に対して適切なレコメンドを行うことは、EC を運営する企業にとって大きな課題となっている。」とも述べている。このことから、レコメンドは消費者に何らかの影響を与えるということが推察できる。

2. 「信頼」に関する既存研究

「信頼」に関する研究について、McAllister[1995]は「信頼には二つの種類がある」と述べており、合理的な評価に基づく信頼である「認知的信頼」と安心感や共感、親しみといった感情に基づく信頼である「情動的信頼」であると示している。また、Glikson and Wooley[2020]は、「AI 導入が成功するかどうかを決める最大の要因は『信頼』である」と述べており、Komial and Benbasat[2006]は実際の AI 推奨システムの研究にて、「信頼の二次元構造は AI 推奨システムにおいても適応可能であり、AI も両方満たす必要がある」ことを示唆している。よって信頼の二次元モデルは対人関係におけるものとして定義されたが AI システムに対する信頼の質を分析する上でも有効な枠組みであると推察できる。

3. 「レコメンド手法」に関する既存研究

レコメンド手法についての分類は複数存在するため主要な二つの手法を整理していく。

Pazzani and Bilsus[1997]は、推薦技術にはコンテンツベースおよび協調フィルタリングがあると述べている。また、「コンテンツベース・フィルタリングはユーザーが過去に好んだアイテムの特徴（キーワードや属性）を分析し、それに類似したアイテムを推薦する手法である」とし、協調フィルタリングは「ユーザーとアイテムの相互作用に基づいて推薦を行う手法である」としている。特にユーザーベースの協調フィルタリングはユーザー同士の相互性をもとに推薦を行うと示している。

4. 既存研究まとめ

以上より、レコメンド自体は、消費者が商品の購買時の行動に重要な役割を果たすことがわかった。そして、対人関係の信頼に用いられる「認知的信頼」「情動的信頼」の二次元モデルを AI への信頼の枠組みとしても捉えられることが分かった。また、それぞれ認知的信頼の醸成にはコンテンツベースフィルタリング（以下コンテンツベース）、情動的信頼の醸成にはユーザーベース協調フィルタリング（以下協調フィルタリング）の手法を用いることができるこ

とが推察できた。しかし、これらの二次元モデルとレコメンド手法を用いてAIと店員のレコメンドを比較する研究はいまだに行われていない。

5. 現状分析

本節では、認知的信頼と情動的信頼を醸成するロジックについて説明する。

「認知的信頼」とは、相手の有能さや責任感などの特性に関する認知に基づく信頼である。ここでの「有能さ」とは、ユーザーの明示的な要求（検索条件や過去の視聴履歴など）を正確に処理し、論理的に矛盾のない結果を返す処理能力や正確性として知覚される。コンテンツベースはアイテムの属性（タグ・ジャンル・成分）などを厳密に分析し、因果関係が明確な論理で推薦を行う。よってコンテンツベース型レコメンドはユーザに対し、システムが自身の嗜好を正確に分析し処理しているという有能さの認知を促し結果として認知的信頼を醸成する。
次に「情動的信頼」とは、相手の幸福・繁栄に対する気遣いや関心に基づいた個人間の情緒的な絆を基盤とする信頼である。ここでの「気遣い」はユーザーの潜在的満足を追求する姿勢として情緒的な絆として現れる。論理としての商品のスペックそのものを超えて、他者の評価や集合的な満足度を判断基準とする。無機質なスペックよりも感情を重視して提案しているという事実はユーザーの利益を優先する姿勢として知覚される。よって、人間味のあるアプローチである共感を取るため協調フィルタリング型レコメンドは情動的信頼を醸成する。
したがって、それぞれ認知的信頼の醸成にはコンテンツベースフィルタリング（以下、コンテンツベース型レコメンド）、情動的信頼の醸成にはユーザーベース協調フィルタリング（以下、協調フィルタリング型レコメンド）の手法を用いることができることが推察できた。

6. 問題提起

既存研究より、対人関係とAIの双方に適用できる信頼の二次元モデルが存在することが分かった。そして、現状分析より、認知的信頼の醸成にはコンテンツベース型レコメンドの手法を用いることができ、情動的信頼の醸成には協調フィルタリング型レコメンドの手法を用いることができることが推察された。しかし、信頼の二次元モデルをもとにしたレコメンド手法を用いたAI・店員のレコメンドが消費者にどのように受け取られているのかは未だ解明されていない。
マーケティングにおけるレコメンドは、顧客の好みを理解して購買意欲を刺激することを目的とした「推奨」機能のことを指す。よって、本研究ではレコメンドに対する消費者の購買意向（以下、購買意向）に絞って調査を実施する。
以上を踏まえて、本研究では、選択段階において、信頼を形成するために推薦主体（AIレコメンドと店員レコメンド）と推薦根拠（協調フィルタリングとコンテンツベース）のどの組み

合わせが適切なのかを明らかにするべく、以下のリサーチ・クエスチョン（以下、RQ）を設定する。

RQ1.　選択段階において、推薦主体と推薦根拠の組み合わせが購買意向にどのような影響を与えるのか。

RQ2.　推薦主体と推薦根拠の適合効果は、消費者の製品関与度の高低によって変化するのか

RQ3.　影響を与える場合その要因は何か。

Ⅲ――Study1

1.　仮説設定

RQ1 を解明するにあたって、仮説を設定する。

①　コンテンツベース型レコメンド

コンテンツベース型レコメンドは、商品の属性とユーザーの要求を照合する論理的処理に依存している。この領域において AI は明確な優位性を持っている。Simon[1955]の限定合理性によると、人間は増大な商品データや複雑な属性を完全に記憶・比較することは認知的に不可能である。対して AI はデータベース内の全商品を瞬時に照合することが可能である。また、Logg, Minson, and Moore[2019]によると、人々は主観的な判断よりも、理論的で客観的な処理が求められるタスクにおいて、人間の判断よりもアルゴリズムを課題に評価・信頼するとしている。加えて、Sundar[2008]は「機械が生成した情報は人間のような偏見（Bias）がなく、客観的で正確であると自動的に信じ込む心理的近道を持っている」と示したおり、純粋な論理的帰結として知覚されることを表している。したがって AI とコンテンツベース型レコメンドの適合性は高いと推察した。

②　協調フィルタリング型レコメンド

Tajfel and Turner[1979]の社会的アイデンティティ理論に基づくと、ユーザーは店員を「自分と同じ感情や感覚を持つ存在(In-group)として認識する一方、AI は感情を持たない異質な存在(Out-group)とみなすとされており、内集団からの情報はより信頼されやすく、受容されやすい。また、Chaldini[2001]は、社会的証明の影響力は、参照対象が自分と類似している場合に最大化されると論じている。AI が提示する統計データとしての他者よりも店員が媒介する実

感の方が類似性が高く、バンドワゴン効果による同調行動を強力に誘発すると推察される。一方、Castelo, Bos, and Lehmann[2019]によると消費者は「感情や経験」を必要とする主観的選択において、アルゴリズムよりも人間を信頼する傾向があると述べている。そのため店員と協調フィルタリング型レコメンドは適合性が高いと推察した。

以上二つの推薦根拠の適合性を踏まえ、以下の仮説を設定する。

仮説 1-1. 店員条件では協調フィルタリング型レコメンドが購買意向により強い正の影響を与える

仮説 1-2. AI 条件ではコンテンツベース型レコメンドが購買意向により強い正の影響を与える

2. 調査前提

（1）分析方法

本研究における統計解析には全て HAD を用い、統計的有意水準を 5%未満に設定する。

（2）商材選定

次に、本研究における商材を選定する。

まず、デプスインタビューを行い、レコメンドが影響を与える場面で想起する商材についての調査を行った。またこの際、本研究における主要な被験者が学生であることから自身で情報探索し購買を行う商材に絞って回答を行ってもらった。調査概要は、図表 2 の通りである。

■図表―――2

商材に関する調査概要

調査期間	2025 年 11 月 25 日
調査対象	20～23 歳の男女
サンプルサイズ	20 人
実施方法	デプスインタビュー
質問項目	自身で情報探索を行い、購買を検討する商材についてレコメンドが

	影響を与える商材について自由に回答

（出典：調査結果をもとに筆者作成）

調査の結果、衣服と靴をまとめたアパレル商品が最も多い回答を集め、商材の候補となった。

さらに、レコメンドの効果を測定するための商材を検討するうえで、商材の特性を考慮する必要があると考えた。そこで、本研究ではVaughn［1980］によって提案されたFCBグリッドを基に以下の観点より商材を靴、特に男女の選好の差を考慮して「スニーカー」に選定した。

一点目は、スニーカーがどちらかというと関与度の高い商材であることが挙げられる。渡辺［1992］は、「当該商品に対する関与が低い場合には、消費者はその商品に関する情報探索をあまり行わないとされている」（p.172）と述べている。

つまり、購買意向を測るにあたり、商材は関与度の低いものではなく関与度の高いものである必要がある。そこで、渕上［2008］が用いた分類手法を採用した。4段階尺度で回答された商品の関与度に関して。商品カテゴリごとに回答者の平均値を算出した。

調査の結果、スニーカーは関与度の高い商品であることが裏付けられたため、条件を満たしていると言える。

二点目に、スニーカーが感情型商品と思考型商品のどちらかに偏っていないことも、選定の理由である。Webアンケート調査により、各商品の分類を行った。4段階尺度で回答された機能的便益と情緒的便益の重要度に関して、商品カテゴリごとに回答者の平均値を算出した。

調査の結果、スニーカーは先述した要素のどちらにも傾きがない商材であることが判明した。Wien, et al［2021］は、思考型商品において、AIによる推奨の方が人間による推奨と比較して効果的であると示している。つまり、商材が感情型商品または思考型商品であることは、購買意向に影響を与えうると言える。したがって、本研究においては中立の立場をとる購買意向は商材として好ましいと考えた。

以上の理由より、スニーカーを本研究で扱う商材として選定した。

（3）プレ調査

本調査において実験を実施するにあたり、店員レコメンドに対して実際の接客現場の文言を確認し再現するために、参与観察に加えてプレ調査としてデプスインタビューを行なった。また、リストアップしたフレーズを協調フィルタリング型レコメンドとコンテンツベース型レコメンドの２カテゴリに分類し、実験用シナリオとして採用した。調査概要は図表3の通りである。

■図表―――3

店員レコメンドに関する定性調査

調査期間	2025 年 12 月 2 日
調査対象	20 代の男女
サンプルサイズ	12 人
実施方法	Web アンケート
質問項目	実際の現場でお客様が商品を絞り込み購入を迷っている段階でおすすめする時に使う文言について自由に回答

（出典：筆者作成）

分類されたフレーズの中から、実際の接客現場として自然かつ分類の要素を備えている文言を実験用刺激として採用した（図表 4）。AI レコメンドに関しては Gemini を使用し、こちらに関してもレコメンドチャットとして自然かつ分類の要素を備えている文言を実験用刺激として採用した。なお、それぞれの文言が不自然ではないことは本調査の質問の一つに入れて確認済みである。

■図表―――4

店員レコメンドに関する定性調査の結果

（一部抜粋）

協調フィルタリング	当店で一番人気・全店で人気・ 再入荷・この前も〜用でご購入があった・ちょうど学生さんに人気・リピートも多い
コンテンツベース	ソール部分が他よりも柔らかい・非常に軽い・幅が広めのタイプ・踵が疲れない・中のクッションが分厚い

（出典：筆者作成）

（4）実験の状況設定

本調査で設定した状況設定は以下の通りである。調査の過程では、実際に活用されているレコメンドのチャットを再現した。

本研究では選択段階でのレコメンド効果に焦点を当てるため、「選択肢の絞り込みプロセス」における選択段階に絞って研究を行う。流れは以下の通りである。

① 初期選好の把握

まず、被験者に対しデザインや形状の異なる四種類のスニーカーの画像を提示し、「自分の好み、もしくは購買の検討を考えるものを一つ選択させた（図表 5)。

この際使う商材は結果に男女の選好差が影響しないようジェンダーレスなもの、各性別の好みに近いものなど様々な要因から決定した。加えて事前情報の有無による結果の差異を防ぐため架空の商品で調査を行った。

② レコメンドの提示

続くレコメンド提示画面においては被験者が選択した三種類の商品に対して、条件ごとに異なる推奨主体と推奨根拠を用いたレコメンドメッセージと特定のスニーカーを提示し、回答を求めた（図表 7, 8）。

あらかじめ被験者に好みの商品を選択させた理由は主に以下の 3 点である。

(a) デザイン選好による交絡要因の排除

本実験の目的は推薦主体や推薦根拠の違いが購買意向に与える影響を測定することである。しかし、推薦された商品のためが被験者の好みではなかった場合、メッセージ内容に関わらず「デザインや形状が好みではない」という理由で購買意向が低下する恐れがある。反対にデザインや形状が好みであれば購買意向を極端に上昇させる恐れもある。そのため、あらかじめ好みのデザイン傾向を選択させ、合致した商品を推薦対象とすることでデザインに対する好意度を一定に保ち、メッセージ内容に集中させる。

(b) 実験参加の自分ごと化

自ら選択するという能動的なプロセスを経ることで、被験者の実験刺激に対する関与度を高め、実際の購買場面に近い検討を促すことを意図している。

(c) 実際のレコメンドプロセスの再現

実際の EC サイトにおいて、レコメンドは興味関心という考慮段階の結果に基づいて行われるのが一般的である。関心のない商品を推奨するのではなく、顧客が興味を示した分類の商品に対してあと押しするという実務的なプロセスを再現するためである。

そのほか実験の詳細は補録に記載する。

■図表―――5

Study1　実証実験用スニーカー候補

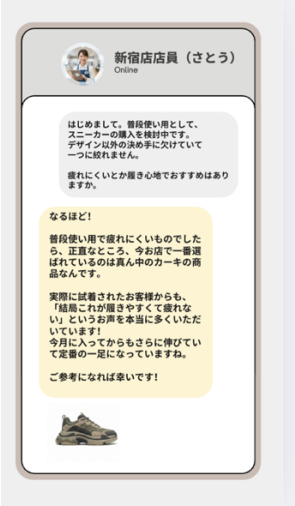


（出典：筆者作成）

■図表―――7

Study1　実証実験用レコメンド画面

例）スニーカーA：店員による協調フィルタリング型レコメンドの場合



（出典：筆者作成）

■図表―――8

Study1　実証実験用レコメンド文言

主体	根拠	内容
店員	協調	正直なところ、今一番お店で選ばれている 実際に試着されたお客様からも～

		定番の一足
	コンテンツ	お客様のご要望には〜がイチオシ ソール部分のクッションが柔らかくて気持ちいい
AI	協調	過去の購買データを参照 最も多くのユーザーに〜ベストセラー商品 レビュー4.8
	コンテンツ	各モデルのスペック情報を照合 衝撃吸収性がシリーズ内で最も高く設計

（出典：筆者作成）

2. 本調査

（1）調査概要

本調査では被験者を「店員による協調フィルタリング型レコメンド」、群と「AIによる協調フィルタリング型レコメンド」群と「店員によるコンテンツベース型レコメンド」群と「AIによるコンテンツベース型の4群に分けた。その後それぞれの群において、レコメンドを体験してもらい、購買意向を測るために、7段階の評定尺度を用いた。推薦主体（AIと店員）と推薦根拠（協調フィルタリング型レコメンドとコンテンツベース型レコメンド）を各被験者間要因とする2×2の二要因分散分析を用い、その後二つの特定の条件や群の間で、統計的に有意な差があるかどうかを平均値の差の検定を用いることで検討する。調査概要は図表9の通りである。

■図表———9

Study1　本調査　調査概要

調査日	2025年12月10~16日
調査対象	20歳以上の男女
調査方法	Webアンケート
サンプルサイズ	161（42/38/36/41）
調査内容	4群それぞれのレコメンドを受けてもらい、その後購買意向について7点尺度で計測

（出典：筆者作成）

（2）検証結果

①-1.二要因分散分析

推薦主体（AI と店員）と推薦根拠（協調フィルタリング型レコメンドとコンテンツベース型レコメンド）を各被験者間要因とする 2×2 の二要因分散分析を用いた。各条件の購買意向の得点を図表 10 に記載した。分析の結果、5%水準で交互作用が有意であった（F(1,157)=5,375,p<.0.5）。これにより、推薦主体によって適切な推薦根拠は異なるという本研究の仮説を支持するものである。具体的には推薦主体には有意な差が見られなかったことから AI 導入に関しては置き換えではなく特性に合致したレコメンド手法を選択できるかどうかに依存していると言える。

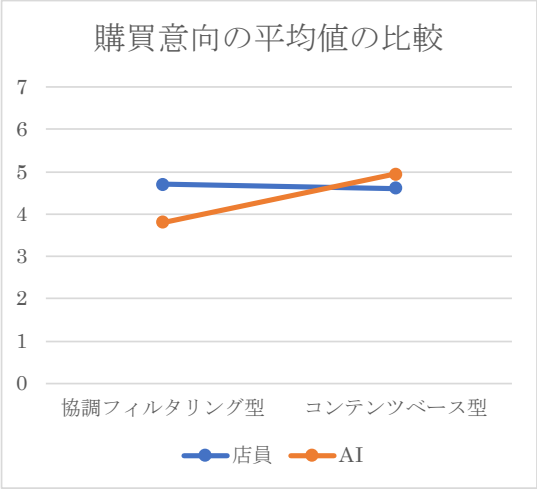
続いて具体的にどういった組み合わせが優位となったのかを調査するために、推薦主体要因の単純主効果と推薦根拠要因の単純主効果の検定を行なった。

■図表―――10

Study1　本調査結果

		平均値	標準偏差
店員（n=82）	協調	4.697	1.372
	コンテンツ	4.615	1.290
AI（n=79）	協調	3.865	1.618
	コンテンツ	4.952	1.303

変数名	偏 η^2	*F*値	*p*値
推薦主体	.008	1.262	.263
推薦根拠	.032	5.189	.024*
交互作用	.043	7.028	.009**



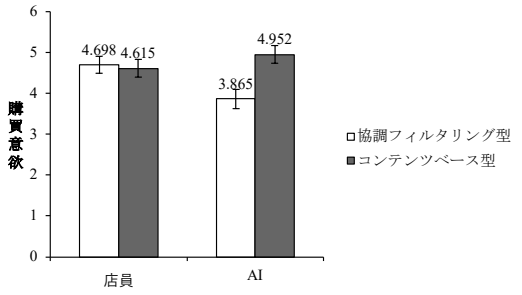
（出典：分析結果をもとに著者作成）

①-2.推薦主体の単純主効果の検定

交互作用が優位であったため、続いて推薦主体の単純主効果の検定を行った。その結果、店員条件においては推薦根拠の違いによる購買意向の有意な差は見られなかった（$F(1,157)=0.071, p>.05$）。一方、AI 条件においては推薦根拠による有意な差が認められた（$F(1,157)=11.916, p<.01$）。これらの分析結果は図表 11 の通りである。その他の数値に関しては補録に記載する。

■図表―――11

Study1　本調査結果



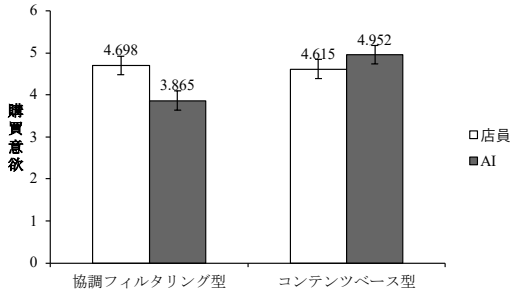
（出典：分析結果をもとに著者作成）

①-3.推薦根拠の単純主効果の検定

続いて推薦根拠の単純主効果の検定を行なった。その結果、協調フィルタリング型条件においては推薦主体の違いによる購買意向の有意な差が認められた（$F(1,157)=7.065, p<.01$）。一方、コンテンツベース型条件においては推薦主体の違いによる有意な差が認められなかった（$F(1,157)=1.176, p>.05$）。これらの分析結果は図表 12 の通りである。その他の数値に関しては補録に記載する。

■図表―――12

Study1　本調査結果



（出典：分析結果をもとに著者作成）

二要因分散分析の結果、二要因が組み合わさったときにより効果が現れることを示している。そのため、店員と AI では効果的な推薦根拠は異なると言える。また、推薦主体の単純主効果の比較により店員の場合は、協調フィルタリング型レコメンドの方が購買意向を高めたものの、スペック説明のコンテンツベース型レコメンドでも人気の紹介の協調フィルタリング型レコメンドでも説得の効果に大きな差はないことが明らかとなった。一方で、AI の場合はどちらの推薦根拠かによって効果が大きく変化し、コンテンツベース型レコメンドの方が購買意向を高めることがわかった。さらに推薦根拠の単純主効果の比較により、AI が協調フィルタリング型レコメンドにより共感を語った場合、店員に比べて著しく購買意向が低くなることがわかった。しかし、コンテンツベース型レコメンドを用いると、店員との差はほとんどなくなりそれ以上の購買意向を示すことも明らかとなった。

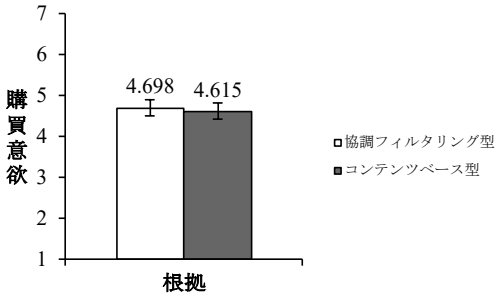
この結果に対して、統計的な有意差があるかを確認するため平均値の差の検定を実施した。具体的には協調フィルタリング型レコメンドにおける店員レコメンドと AI レコメンドの比較を行い、コンテンツベース型レコメンドも同様に比較を行なった。

②平均値の差の検定

店員による協調フィルタリング型レコメンドとコンテンツベース型レコメンドにおける購買意向の平均値の差の検定を行った。その結果、5%水準で統計的に有意な差が見られなかった。よって店員の場合、協調フィルタリング型レコメンドはコンテンツベース型レコメンドと比較して購買意向に正の影響を与えるとは言えなかった。分析結果は図表 13 の通りである。

■図表―――13

店員によるレコメンドにおける平均値の差の検定



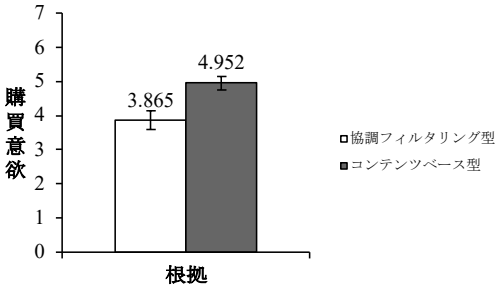
	平均値	p 値	効果量（d）
協調	4.698	.781	0.061
コンテンツ	4.615		

（出典：分析結果をもとに著者作成）

続いて AI による協調フィルタリング型レコメンドとコンテンツベース型レコメンドにおける購買意向の平均値の差の検定を行った。その結果、5%水準で統計的に有意な差が見られた。そのため、AI においては、コンテンツベース型レコメンドは協調フィルタリング型レコメンドと比較して、購買意向に正の影響を与えることが確認できた。分析結果は図表 14 の通りである。

■図表―――14

AI によるレコメンドにおける平均値の差の検定



	平均値	p 値	効果量（d）
協調	3.865	.002	-0.737
コンテンツ	4.952		

（出典：分析結果をもとに著者作成）

よって仮説 1−1 は支持されず、仮説 1−2 は支持された。つまり、店員によるレコメンドでは推薦根拠の購買意向への影響はほとんど見られず、AI によるレコメンドでは推薦根拠の購買意

向への影響は大きく、特にコンテンツベース型レコメンドの組み合わせが購買意向に正の影響を与えている可能性があることが分かった。

（3）考察

Study 1 の結果で有意な交互作用が確認されたことより、推薦主体と推薦根拠が互いに影響しあい、特定の条件下で効果が変化することが判明した。具体的には仮説の検証より、仮説 1-1 は支持されず、店員は両方の推薦根拠において高い購買意向が維持される結果となった。一方で仮説 1-2 は支持されたという結果になったことから、AI はその特性に合ったスペックに焦点を当てたコンテンツベース型レコメンドが適しており、協調フィルタリング型レコメンドでは購買意向が落ちる結果となった。この結果においてそれぞれ考察を行う。まずは支持となった仮説 1-2 の AI 条件は、Sundar[2008]が「機械が生成した情報は人間のような偏見（Bias）がなく、客観的で正確であると自動的に信じ込む心理的近道を持っている」と示している通り、消費者は膨大なデータ処理能力に基づいた機械的な客観性を期待する傾向があると言える。反対に自身のニーズとは無関係な協調フィルタリング型のような他者との協調に関わる情報は AI が本来得意とするパーソナライゼーションとは相反する効果を示したと考えられる。次に棄却された仮説 1-1 の店員条件は仮説設定時、周囲の動向などの社会的情報を伝える主体として適していると考えたが、結果はほぼ同等となった。今回推薦根拠による差が見られなかった要因として情報源ヒューリスティックの働きが考えられる。Chaiken[1980]によると、情報源への信頼が十分に高い場合、受け手はメッセージを商材に吟味・処理することを省略する傾向があると示している。本実験においても店員の対人的な影響力が存在していたため購買意向の決定において推薦根拠の違いが相対的に重要視されなかったと思われる。AI では対人的なヒューリスティックが働かないため消費者は根拠の妥当性などを冷静に評価し有意差という結果として生じたと考えられる。

以上の考察から、EC サイトやアプリ内での AI によるレコメンドを設計する場合には売れ筋をアピールするだけでなく、スペックや嗜好性についてのコンテンツベースのロジックを提示することで購買意向を最大化できると考えた。また、店員は双方のアプローチの仕方が有効であるため顧客の反応に応じてアプローチを使い分けることが有効であると推察できる。

ただ、本研究では商材をスニーカーに絞っているため消費者の心理状態、特に消費者の製品関与度については考慮しておらず、全ての消費者が同様に情報を処理するわけではないことも十分に考慮すべき点である。マーケティングおよび消費者行動論において、そのような情報処理プロセスを説明する理論としては Petty and Cacioppo[1986]の精緻化見込みモデルが存在する。この理論によると、消費者の関与度（こだわりや重要性）が高い場合は内容面での論理的な情報を重視し、低い場合は周辺的な手がかりを重視するとされる。この理論が AI レコメン

ドにも適用されるのであれば消費者の製品関与度次第で結果が変化する可能性があると考えた。

以上を踏まえて商材に対しての関与度が高い人と低い人で結果が変わるのかを探るため、次節にて検証を行なった。

Ⅳ──Study2

前章より、協調フィルタリング型において店員レコメンドはAIレコメンドと比較して購買意向に正の影響を与え、コンテンツベース型ではAIレコメンドは店員レコメンドと比較して購買意向に正の影響を与える可能性があることが明らかになった。つまり、推薦主体と推薦根拠の適合性が購買意向に影響を与えることが明らかとなった。特にAIにおいては論理的訴求が有効であり情緒的訴求は逆効果となる傾向が確認できた。

本章ではPetty and Cacioppo[1986]の精緻化見込みモデルに基づいて商材に対しての関与度が高い人と低い人で結果が変わるのかを探るため、被験者の商材に対しての関与度により高関与グループと低関与グループに分類し、改めて二要因分散分析を行なった。これによりターゲット層によるAIと店員の使い分けの効果について解明する。

そこでStudy2では製品関与度を新たな要因としてモデルに加え、以下のRQを再設定する。

RQ2.推薦主体と推薦根拠の適合効果は、消費者の製品関与度の高低によってどのように変化するのか

１．　調査方法

本章の調査目的は、推薦主体と推薦根拠の適合効果が消費者の製品関与度の高低で調整されるのかを解明することである。Study2ではこちらについて検証を行うためStudy1で用いたデータに対して製品関与どのスコアに基づく事後的な分類分けを行った。具体的には全被験者の関与度スコアの中央値を基準としデータを二分割した。中央値以上の群を高関与群、中央値未満の群を低関与群と定義した。

そしてStudy1同様推薦主体と推薦根拠をそれぞれ被験者感要因として二要因分散分析を高関与群、低関与群それぞれに対して用いて検証した。その後、二つの特定の条件や郡の間で統

計的に有意な差があるかどうかを平均値の差の検定を用いることで検討する。調査概要は図表15の通りである。

■図表―――15

Study1　本調査　調査概要

調査日	2025年12月10~16日
調査対象	20歳以上の男女
調査方法	Webアンケート
サンプルサイズ	161（42/38/36/41）
調査内容	４群それぞれのレコメンドを受けてもらい、 その後購買意向について7点尺度で計測 アンケート内で同被験者に関与度についても 計測

（出典：筆者作成）

２．　仮説設定

Study2の主題である製品関与度に関して以下のように検討した。

製品関与度が高い消費者は情報の論理性を重視し、関与度が低い消費者は発信者の属性や周辺的手がかりを重視するとされる(Petty and Cacioppo[1986])。そのため高関与群においてはコンテンツベース型レコメンドが有効であると推測される。一方、関与度の低い消費者は直感的な周辺ルートで処理するため、発信者の印象に左右されやすい。AIの発信する違和感を敏感に察知し評価を下げるのではないかと考えた。したがって、Study1で示された適合効果は消費者の製品関与度によってその現れ方が異なる可能性がある。

よってStudy2では新たに以下の三つの仮説も設定した。

仮説2-1.　消費者の製品関与度は推薦主体と推薦根拠の購買意向への影響を調整する

仮説2-2.　製品関与度が高い消費者においては、推薦主体の影響は弱まり、推薦根拠の論理性（特にコンテンツベース型）が購買意向に正の影響を及ぼす

仮説 2-3.　製品関与度が低い消費者においては推薦主体と推薦根拠の交互作用が強く影響し、AI が協調フィルタリング型レコメンドを行った場合、購買意向が低下する

３．　検証結果

①　高関与群

高関与群に分類分けしたのち、Study 1 と同様に二要因分散分析を行なった。

まずは高関与群において推薦主体（AI と店員）と推薦根拠（協調フィルタリング型レコメンドとコンテンツベース型レコメンド）を各被験者間要因とする 2×2 の二要因分散分析を用いた。各条件の購買意向の得点を図表 16 に記載した。分析の結果、Study1 の結果とは異なり 5%水準で交互作用は有意でなかった（F(1,77)=1.528,p>.0.5）。一方で、推薦根拠においては 1%水準で有意となった。

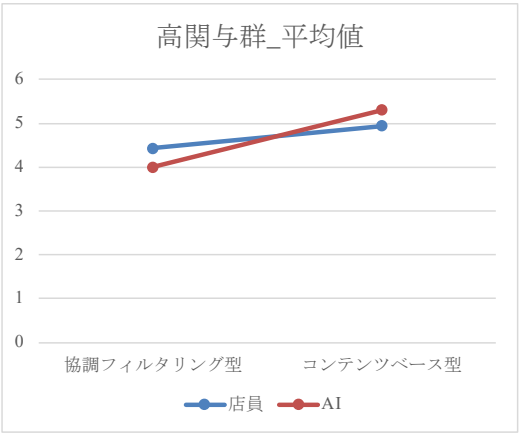
これにより、推薦主体によって適切な推薦根拠は異なるという Study1 の結果とは異なり、製品に対する関与度が高い層においては推薦主体の主効果は見られず、推薦根拠の主効果のみが有意となる結果となった。この結果は精緻化見込み理論と合致する。なお、今回交互作用が認められなかったため単純主効果の検定も行わなかった。

図表―――16

Study2　本調査結果

		平均値	標準偏差
店員（n=40）	協調	4.435	0.287
	コンテンツ	4.941	0.337
AI（n=41）	協調	4.000	0.390
	コンテンツ	5.300	0.242

変数名	偏 η^2	F値	p値
推薦主体	.000	0.014	.906
推薦根拠	.093	7.915	.006**
交互作用	.019	1.528	.220



（出典：分析結果をもとに著者作成）

②　低関与群

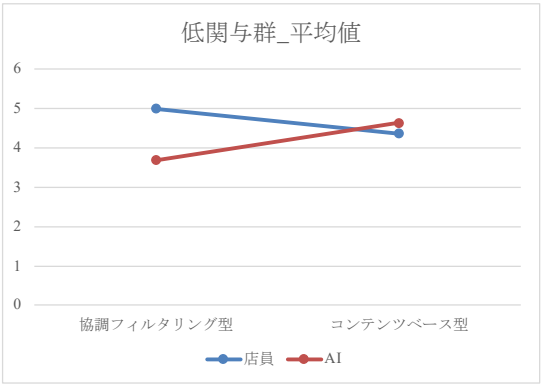
低関与群に分類分けしたのち、Study1 と同様に二要因分散分析を行なった。高関与群と同様に二要因分散分析を行い、各条件の購買意向のスコアを図表 17 に記載した。分析の結果、高関与群とは異なり、5%水準で交互作用は有意であった（F(1,77)=6.923,p<.0.5）。これにより低関与群の被験者は交互作用に依存し、組み合わせの適合性が重要であることが示された。

図表―――17

Study2　本調査結果

		平均値	標準偏差
店員（n=42）	協調	5.000	1.338
	コンテンツ	4.344	1.177
AI（n=38）	協調	3.688	1.448
	コンテンツ	4.636	1.399

変数名	偏 η^2	F値	p値
推薦主体	.038	2.979	.088
推薦根拠	.004	0.269	.605
交互作用	.083	6.923	.010*



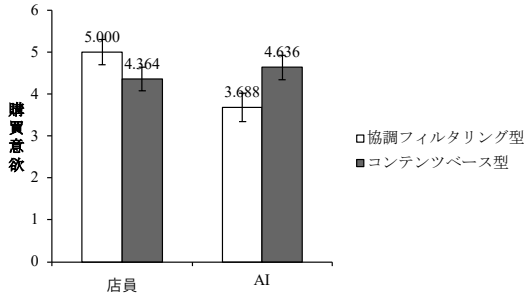
（出典：分析結果をもとに著者作成）

①単純主効果の検定

交互作用が優位であったため、続いて推薦主体の単純主効果の検定を行なった。その結果、店員条件においては協調フィルタリング型レコメンドの方が高いが、統計的な有意差は見られなかった(F(1,76)=2.377,p>.05)。一方 AI 条件においては推薦主体の違いによる購買意向の有意な差が認められた(F(1,76)=4.674,p<.05)。これらの分析結果は図表 18 の通りである。その他の数値に関しては補録に記載する。

■図表―――18

Study2　本調査結果

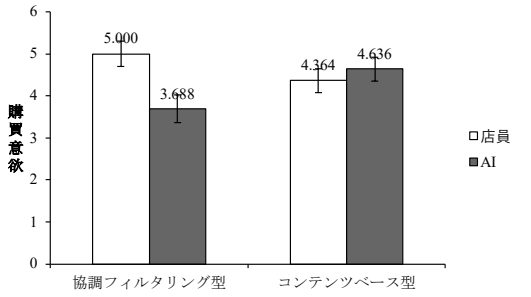


（出典：分析結果をもとに著者作成）

次に推薦根拠の単純主効果の検定を行なった。その結果、協調フィルタリング型レコメンド条件においては、AI と店員では店員の方が高く、有意な差が見られた（$F(1,76)=8.581, p<.01$）。一方コンテンツベース条件においては統計的な有意差は見られなかった（$F(1,76)=0.459, p>.05$）。これらの分析結果は図表 19 の通りである。その他の数値に関しては補録に記載する。

■図表―――19

Study2　本調査結果



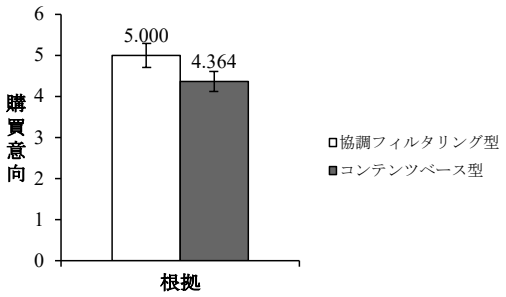
（出典：分析結果をもとに著者作成）

③　平均値の差の検定

低関与群においても店員による協調フィルタリング型レコメンドとコンテンツベース型レコメンドにおける購買意向の平均値の差の検定を行った。その結果、5%水準で統計的に有意な差が見られなかった。よって店員の場合、協調フィルタリング型レコメンドはコンテンツベース型レコメンドと比較して購買意向に正の影響を与えるとは言えなかった。分析結果は図表 20 の通りである。

■図表―――20

店員によるレコメンドにおける平均値の差の検定



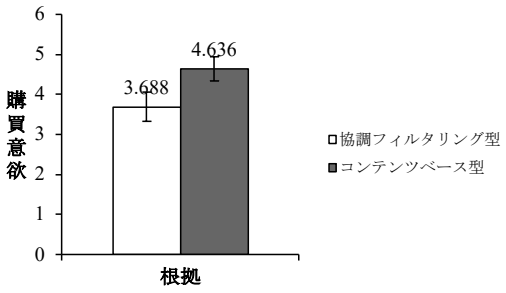
	平均値	p 値	効果量（d）
協調	5.000	.109	0.873
コンテンツ	4.364		

（出典：分析結果をもとに著者作成）

続いて低関与群の AI による協調フィルタリング型レコメンドとコンテンツベース型レコメンドにおける購買意向の平均値の差の検定を行った。その結果、5%水準で統計的に有意な差が見られた。そのため、AI においては、コンテンツベース型レコメンドは協調フィルタリング型レコメンドと比較して、購買意向に正の影響を与えることが確認できた。分析結果は図表 21 の通りである。

■図表―――21

AI によるレコメンドにおける平均値の差の検定



	平均値	p 値	効果量（d）
協調	3.688	.049	-0.654
コンテンツ	4.636		

（出典：分析結果をもとに著者作成）

分析結果より、製品関与度は購買意向への影響を調節することがわかり、仮説 2-1 は支持となった。また、仮説 2-2 についても推薦根拠のコンテンツベース型が有意隣支持される結果となった。際の仮説 2-3 に関しても Study1 と同程度の結果となり、支持された。

４．　考察

本節では、実験結果に基づいた考察を行う。

まずは、製品関与度が高い消費者は情報の論理性を重視し、関与度が低い消費者は発信者の属性や周辺的手がかりを重視するとされる(Petty and Cacioppo[1986])ことから、高関与群、低関与群ともに仮説通りの結果となった。関与度の高い中心ルートを重視する消費者は誰が行ったかはどうでもよく、なんと言ったか（特にスペックという質の高い情報のみ）で判断したため推薦主体では差がつかず、コンテンツベースのみが有意となった。関与度の低い周辺ルートを重視する消費者は情報の質よりも推薦主体やAIの適合性、違和感がないかと言った印象に左右されたためAIと協調フィルタリングという組み合わせの時に評価が落ちたと考えられる。この結果にはGray, Gray, and Wegner[2007]によるマインド・パーセプション理論も結果の根拠として説明できる。「人間は他者の心を二つの次元で知覚する。ロボットやAIに対してエージェンシー（＝知能）は認めるが、エクスペリエンス（＝感情）は認めない」というものである。これより共感のレコメンドを行うとエクスペリエンスの欠如から説得力が欠けてしまったとも言える。

Ⅴ──Study3

これまで、後押しを必要とする選択段階では店員による協調フィルタリング型レコメンドが購買意向に正の影響を与え、AIによるコンテンツベース型レコメンドも購買意向に正の影響を与えることが明らかになった。また、高関与群に絞ると結果が変化し、推薦根拠という内容重視の購買意向が高まることが明らかになった。ではそもそもそれぞれのレコメンドが購買意向に正の影響を与えた要因は何か。本章では、Study1、2の結果よりAIと店員のどの要素が評価されたのかのメカニズムを解明する。ここで、三つ目のRQを再設定する。

RQ3.　レコメンド手法の違いが購買意向に正の影響を与える場合、その心理的要因は何か

1.　調査方法

本章の調査目的は、今回用いたレコメンド手法が、購買意向に正の影響を与える特有の要因を解明することである。では本調査の流れを説明する。

今回は推薦主体と推薦根拠にかかわらず、消費者は評価する際の心理的構造は共通であると仮定し、全条件のデータを統合して探索的因子分析を行い、抽出された因子について検証するた

め購買意向を従属変数とし、まず主効果モデルとして因子のみを投入して因子の購買意向へ与える影響を確認し、次に交互作用項を追加投入しその係数が有意であるかを検討することで推薦主体による違いがあるのかを検証する。

まず、プレ調査として4群それぞれ別の被験者に状況を説明した上で、デプスインタビューを行い、それぞれの状況における印象を回答してもらった。

その後、デプスインタビューで得られた印象に対する回答を質問項目に集約し、印象とその購買意向を測定する質問項目について、それぞれ7段階尺度で回答してもらった。

次に因子分析を行い、印象に関する因子を抽出する。続いて重回帰分析の結果、抽出された各因子が満足度にどれくらい影響を与えているか明らかにする。

2. プレ調査

(1) 要因抽出

まず、消費者がAIおよび店員のレコメンドの印象を抽出するため、実験の被験者にデプスインタビューを実施した。調査概要は図表22の通りである。また、調査を通して得られた回答をもとに、印象に関しての質問項目を作成した。（図表23）質問の内容の詳細については補録に添付する。

■図表―――22

Study2　プレ調査　調査概要

調査期間	2025年12月8日
調査対象	20～23歳の男女
サンプルサイズ	15人
実施方法	デプスインタビュー
質問項目	レコメンドを受けた感想についてインタビュー

（出典：筆者作成）

■図表―――23

デプスインタビューの回答（一部抜粋）

・客観的な事実に基づいている ・偏りや無理な売り込みを感じない ・頼りになると感じる		・提案によっておすすめなものがわかった ・温かみを感じた ・論理的でデータに基づいている

（出典：調査結果をもとに筆者作成）

（2）探索的因子分析

続いて、各レコメンドが購買意向に正の影響を与える因子を抽出するために、因子分析を実施した。調査概要は図表 24 の通りである。被験者に店員によるレコメンドもしくは AI によるレコメンドを実際に受けてもらった。その後先ほど集約した 11 の質問項目に対して、それぞれ 7 段階尺度で回答してもらった。調査後、それぞれに対して探索的因子分析を行った。因子分析の結果は図表 25 の通りである。質問の内容の詳細については補録にアンケートフォームを添付する。

■図表―――24

Study2　プレ調査　調査概要

調査期間	2025 年 12 月 10~16 日
調査対象	20～23 歳の男女
サンプルサイズ	161 人（対応なし）
実施方法	Web アンケート
質問項目	デプスインタビューをもとに作成した質問項目について 7 段階尺度で回答

（出典：筆者作成）

■図表―――25

レコメンドに対する共通因子

項目	Factor1	Factor2	共通性
倫理的でデータに基づいていると思う	**1.016**	-.170	.808
公平・中立的な視点からのものだと感じる	**.858**	-.003	.732
客観的な事実に基づいていると感じる	**.782**	.109	.747
商品の良し悪しを適切に判断できる能力がある	**.738**	.125	.695
偏りや無理な売り込みを感じない	**.612**	.086	.459
提案にはスニーカーに関する十分な知識があると感じる	**.556**	.288	.626
この提案の内容には専門的な説得力がある	**.510**	.399	.716
この提案のおかげで自分に合った商品だと確信できた	-.090	**1.022**	.918
提案された商品は個人にピッタリ合うものだと感じる	-.078	**.990**	.873
私の好みやニーズを理解していると感じる	.180	**.699**	.705
提案者のアドバイスは頼りになると感じる	.331	**.575**	.719

（出典：筆者作成）

今回の因子分析では、推定法として最尤法を選択し、因子数の決定には固有値 1 以上を基準とするガットマン基準を用いた。また、回転法は因子間の相関を考慮し、プロマックス回転を用いた。本研究では、因子負荷量の採用基準は 0.40 以上とし、十分な因子負荷量を示さなかった項目を除外した。さらに因子の信頼性と妥当性を持たせるために、二つ以上の因子に対して因子負荷量が 0.40 以上ある項目も除外した。このように因子分析を繰り返した結果、二つの因子が抽出されている。ここで、クロンバックの α 係数を用いて質問項目が各因子を十分に説明できているかを検証したところ、全ての因子において α 係数が 0.70 を越えたため、Nunnally［1978］の測定尺度を参考に，信頼性は十分であると判断した（図表 26）。

■図表―――26

因子分析　結果

選択段階	Factor1	Factor2
α 係数	.931	.935

（出典：分析結果をもとに筆者作成）

観測変数から抽出された因子については、質問項目を加味した上で、第 1 因子から順に「有能性因子」、「客観性因子」と命名した(図表 27)。

■図表―――27

抽出された因子の観測変数と質問項目

有能性因子	この提案のおかげで自分に合った商品だと確信できた
	提案された商品は個人にピッタリ合うものだと感じる
	私の好みやニーズを理解していると感じる
	提案者のアドバイスは頼りになると感じる
	提案にはスニーカーに関する十分な知識があると感じる
	この提案の内容には専門的な説得力がある
	商品の良し悪しを適切に判断できる能力がある
客観性因子	倫理的でデータに基づいていると思う
	公平・中立的な視点からのものだと感じる
	客観的な事実に基づいていると感じる
	偏りや無理な売り込みを感じない

(出典：分析結果をもとに筆者作成)

3. 仮説設定

RQ2 を解明するにあたり、仮説を設定する。

① 仮説 3-1

本研究において信頼理論において、情報源に対する「信頼」や「有用性の知覚」は購買意向を高める決定要因であることが示されている。したがって推薦者に関わらず推薦のメッセージ内容に有能性や客観性を感じた消費者は購買意向を高めると考えられる。

② 仮説 3-2

機械学習である AI はデータ処理に優れており、人間である店員は経験や文脈理解に優れている。そのため消費者は AI に対して「計算能力」や「客観的なデータ処理」を期待する傾向があるため AI レコメンドにおいては情報の「客観性」が担保されているが購買の後押しをすると推察でき、一方で店員に対しては経験に基づく専門知識や対応力を期待するため店員レコメンドにおいては「有能性」を感じることが購買の後押しをすると推察できる。

これらを踏まえ、以下 2 つの仮説を設定する。

仮説 3-1.　「有能性因子」と「客観性因子」は推薦主体に関わらず購買意向に対して正の影響を与える

仮説 3-2.　推薦主体によって、各因子が購買意向に与える影響の強さは異なる。店員レコメンドでは AI と比較して「有能性因子」が強く働き、AI レコメンドでは店員と比較して「客観性因子」が強く働く。

4. 本調査

（1）調査概要

仮説を検証するため、本調査を実施する。調査概要は図表 28 のとおりである。前節の因子分析より抽出した、二つの因子の質問項目と、購買意向を図る項目を用いて回答を集計する。そして分析の前処理として、前節の因子分析より抽出された各因子得点を説明変数、RQ1 に関する調査で測定した購買意向を従属変数として、重回帰分析を実施した。この際、調整変数として AI 条件を 0、店員条件を 1 とするダミー変数と、因子得点と推薦主体の積を作成し推薦主体による調整効果も同時に検証する。重回帰分析の投入法は、強制投入法を利用した。

■図表―――28

Study2　本調査　調査概要

調査日	2025 年 12 月 10~16 日
調査対象	20 歳以上の男女
サンプルサイズ	161（42/38/36/41）

実施方法	Web アンケート
質問項目	RQ1 と同様の調査を実施後、プレ調査から集約された 11 の項目に対して 7 段階尺度で回答

（出典：筆者作成）

(2) 分析結果

重回帰分析の結果は図表 29、30 の通りである。

■図表―――29

階層的重回帰分析の結果

因子名	標準化係数	t 値	p 値
切片	4.570	43.990	.000
有能性因子	0.859	3.832	**.000**
客観性因子	0.300	1.328	.186
推薦主体	0.216	1.492	.138
交互作用（有能性）	0.138	0.527	.599
交互作用（客観性）	-0.128	-0.483	.630

（出典：分析結果をもとに筆者作成）

■図表―――30

階層的重回帰分析の結果

適合指標	R^2	Adjust R^2	F 値	df	p 値	AIC	BIC
	.615	.602	49.497	5, 155	.000	422.690	444.260

（出典：分析結果をもとに筆者作成）

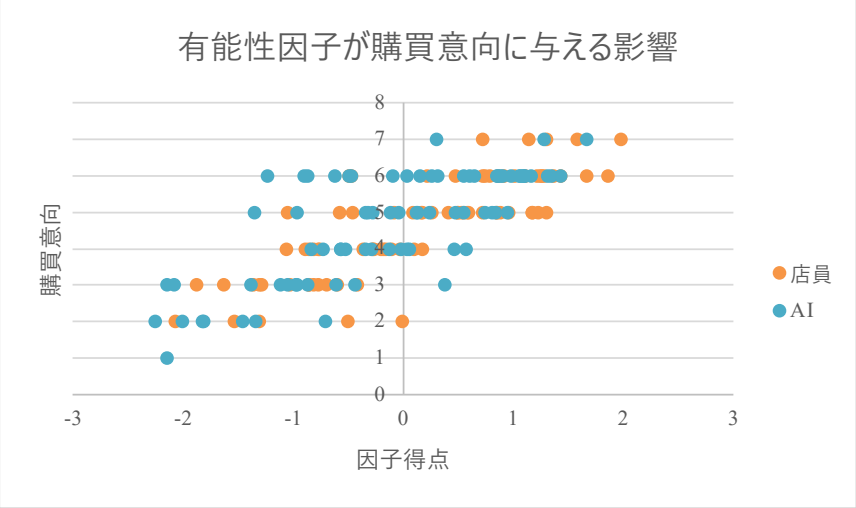
分析の結果、モデルの決定係数は 0.615 と高い値を示し、モデルの妥当性が確認された。各仮説の検証結果は以下のとおりである。

まずは仮説 3-1 についてである。こちらは「有能性因子」は購買意向に対して極めて強い正の優位な影響を与えることが確認された。一方で、「客観性因子」の影響は優位ではなかった。つまり、消費者は情報の客観性よりも推薦主体の有能さを重視して購買を検討していることが判明した(図表 31)。

次に仮説 3-2 についてである。こちらは支持されない結果となった。推薦主体および各因子との交互作用項は全て有意ではなく、p 値も全て 5%水準を上回った。したがって推薦主体の違いによって重視されるポイントが変化することはないということを統計的に示すものとなった。

■図表―――31

有能性因子が購買意向に与える影響



(出典：分析結果をもとに筆者作成)

5. 考察

本節では、検証結果に関して考察を行う。推薦主体が店員であるか AI であるかに関わらず消費者が購買決定において最も重視するのは推薦主体が有能であると感じられるかであることがわかった。AI には客観的なデータ処理を、人間には感情的な対応をといった役割分担とは異なり、本結果は AI であっても有能性を醸成できれば購買意向を高めることができることを示している。ただ一方で今回示している「データ」というのは架空の商品を使うという実験の性質上それまでの購買データを反映しているものではなく執筆者が実店員の経験談や商品の性質をインタビューしたデータをもとに作成してものであるため、実際の自身の購買データやビッグデ

ータをもとにしている様を示すことができれば客観的なデータ性も購買意向を高めるものになったと考えられる。

ただ、本調査においては客観性が購買に結び付かなかったため、消費者がレコメンドを受ける際には単なる事実の羅列よりも自分にとって良い提案をしてくれる能力を求めているためであるとの発見をすることができた。

Ⅶ──おわりに

1. まとめ

本研究では、以前自身で行なった研究を起点としてAIおよび店員によるレコメンドが購買意向に与える影響について再び着目した。今回は、推薦根拠の適合性、製品関与度の調整効果、および心理的因子の観点から検討を行った。

Study1 およびStudy2の低関与群の結果から、店員は推薦根拠の種類に依存せず、安定して高い購買意向を獲得できることが示された。店員条件では協調フィルタリング型レコメンドが数値的に高い傾向にあったものの、統計的な有意差は見られず一定の説得力を持つことが明らかになった。対照的にAIによる推薦は用いる推薦根拠によって効果が大きく異なることが確認された。AI条件においては一貫して製品属性に基づく推薦が協調フィルタリング型よりも優位に高い購買意向をもたらした。これは消費者がAIに対して他者の文脈よりもデータに基づいた属性分析との親和性を感じることを示唆している。そのため、AI活用においては推薦根拠の選択が極めて重要であると言える。

Study2では消費者の製品関与度によって、推薦の受容態度が変容することがわかった。低関与群ではStudy1と同様の交互作用が確認された。しかし、高関与群において交互作用は消失し、推薦主体による差は見られなくなった。その代わり、推薦根拠の主効果としてコンテンツベース型が優位に支持された。これは、製品への関心が高い消費者は誰が薦めたと言う情報よりもどのような根拠かという情報の中身自体を重視するためAIに対するバイアスが低減し、純粋に情報価値の高いコンテンツベース型が評価されたと考えられる。

最後Study3では、なぜこれらの現象が起きるのかの心理的メカニズムを検証した。当初、導き出された因子からAIは客観性、店員は有能性と言うことなる強みが購買を促進すると仮定したが、結果は支持されなかった。分析結果から、推薦主体に関わらず「有能性因子」のみに対し強い正の影響を与え、客観性因子の影響は優位ではなかった。また、推薦主体による調整効果も見られなかった。この結果はStudy1,2で見られたAIによるコンテンツベース型の優位性を説明するものとなった。すなわち、消費者はAIが客観的だから購買するのではなく、コンテンツベースという提示を通じて商品のことをよく理解していると判断した結果、購買意

向を高めたのだと考えられた。逆に店員が推薦根拠によらず強いのは人間という存在が社会的文脈において行っての有能性を期待されているためだと推察できる。

以上の結果から、AI の活用には有能性の演出が不可欠であることが判明した。また、高関与商材や適切に有能性が示された条件下において AI は店員と同等の購買意向を獲得できることから主要な販売チャネルとなりうること、また適切なターゲティングが求められることがわかった。

本研究は、推薦システムの設計において「誰が推薦するか」「どう推薦するか」「消費者は何を感じているか」の主体、方法、心理的評価を統合し、有能性が共通の購買決定要因であることを実証的に明らかにした点に意義がある。

2. 本研究における限界と今後の課題

本研究での限界を提示し、今後の課題とする。

本研究はレコメンドに特化したものであったため、レコメンド以外の接客要素や購買までの過程を考慮出来なかった点である。また、AI のビッグデータを再現することが難しかった点も本研究における限界と言える。そのため、レコメンド以外の接客要素を組み込み、購買までの過程を含めた研究や実際の購買データを用いた研究を行う余地があると考える。

謝辞

最後に、本研究に対し多大なお力添えを頂いた教授をはじめ、先輩方、同期、調査にご協力頂いた全ての方々に感謝の辞を申し上げ、この論文の結びとする。

（19055 字）

参考文献

生田目 崇, 大竹 恒平, 加藤 義明. (2020). 顧客の購買関連データを用いたレコメンデーション. 第11回横幹連合コンファレンス予稿集, B-1-4. https://doi.org/10.11487/oukan.2020.0_B-1-4

Glikson, E., & Woolley, A. W. (2020). Human Trust in Artificial Intelligence: Review of Empirical Research. Academy of Management Annals, *14*(2), 627-660. https://doi.org/10.5465/annals.2018.0057

劉 培. (2014). 認知的・感情的信頼の次元構造と尺度開発：日本と中国のデータを用いて. 神戸大学経営学研究科 Current Management Issues, 2014-05a.

浦田 夏実, 佐藤 扶由夫, 松枝 修. (2023). 「信頼をつくるということ」—主体的信頼創造の可能性—. 支援対話研究, *8*, 20-39. https://doi.org/10.20761/jadcs.8.0_20

劉 培. (2013). 認知的・感情的信頼の次元構造と尺度開発：日本と中国のデータを用いて. 神戸大学大学院生ワーキングペーパー, 2013.05a. https://b.kobe-u.ac.jp/stuwp_files/2013/201305a.pdf

桃谷 裕子, 大塚 泰正. (2022). 職場における情緒的・認知的信頼尺度日本語版の作成と信頼性・妥当性の検討. キャリア・カウンセリング研究, *23*(2), 91-99. https://doi.org/10.34512/careercounseling.23.2_91

Gray, H. M., Gray, K., & Wegner, D. M. (2007). Dimensions of Mind Perception. **Science**, *315*(5812), 619. https://doi.org/10.1126/science.1134475

Komiak, S. Y. X., & Benbasat, I. (2006). The Effects of Personalization and Familiarity on Trust and Adoption of Recommendation Agents. MIS Quarterly, *30*(4), 941-960.

Pazzani, M., & Billsus, D. (1997). Learning and Revising User Profiles: The Identification of Interesting Web Sites. Machine Learning, *27*, 313-331.

Petty, R. E., & Cacioppo, J. T. (1986). The Elaboration Likelihood Model of Persuasion. **Advances in Experimental Social Psychology**, *19*, 123-205. https://doi.org/10.1016/S0065-2601(08)60214-2

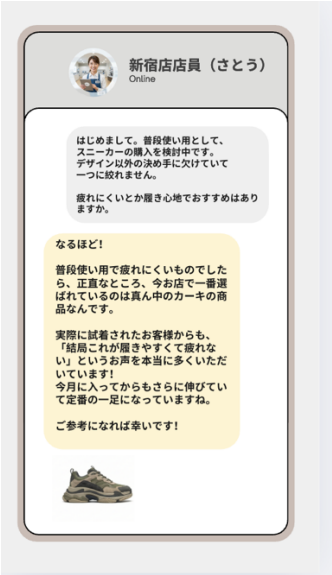
Petty, R. E., & Cacioppo, J. T. (1986). **Communication and Persuasion: Central and Peripheral Routes to Attitude Change**. New York: Springer-Verlag.

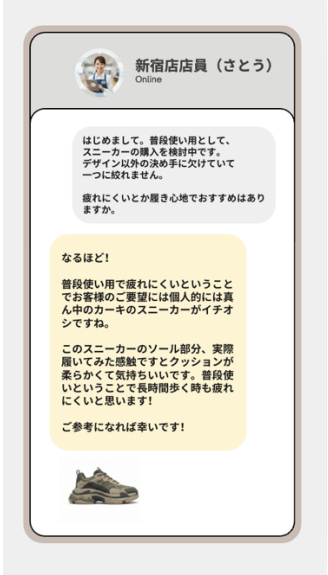
松尾 陽二. (2022). EC サイトのチャットボット導入事例をベンダーが 3 つ紹介！アパレル業界や通販サイトでチャットボットを活用するには？. sAI Chat ブログ. 株式会社サイシード. https://saichat.jp/chatbot/chatbot-ec/, (参照 2026-01-09).

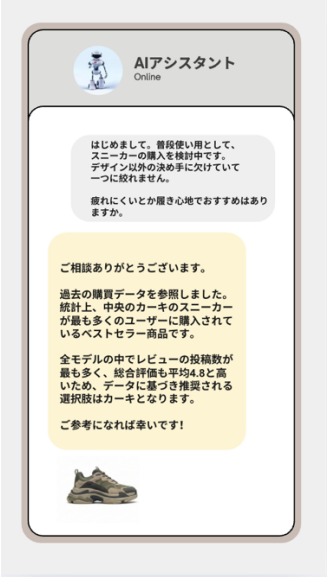
補録

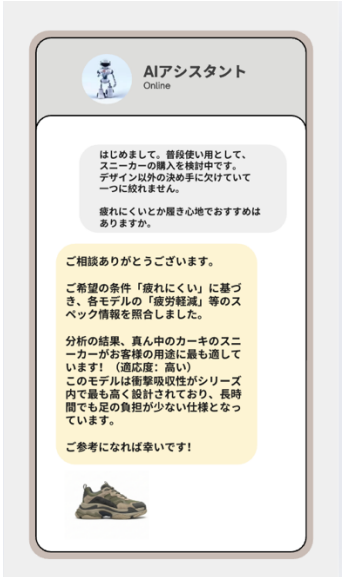
実験詳細：https://forms.gle/k7jAvcs3Px2f8Aec6

補録――――実験画面









補録――――分析結果

Ⅲ―――Study1

【本調査① 二要因混合計画の分散分析】

水準ごとの平均値

		平均値	標準偏差	標準誤差	95%精度	人数
店員	協調	4.698	1.372	0.209	0.422	43
（n=82）	コンテンツ	4.615	1.290	0.207	0.418	39
AI	協調	3.806	1.618	0.270	0.545	36
（n=76）	コンテンツ	4.951	1.303	0.203	0.401	41

交互作用の検証

変数名	SS	MS	MSe	偏 η²	95%CI	*F*値	df1	df2	*p*値
推薦主体	2.465	2.465	1.952	.008	.000, .056	1.262	1	157	.263
推薦根拠	10.132	10.132	1.952	.032	.000,.101	5.189	1	157	.024*
交互作用	13.721	13.721	1.952	.043	.003,.117	7.028	1	157	.009**

単純主効果

スライス	変数名	SS	MS	MSe	偏 η2	95%CI	*F*値	df1	df2	*p*値
店員	根拠	0.138	0.138	1.952	.001	.000,.026	0.071	1	157	.790
AI	根拠	23.265	23.265	1.952	.134	.013,.155	11.916	1	157	.001**

スライス	変数名	SS	MS	MSe	偏 η2	95%CI	*F*値	df1	df2	*p*値
協調	主体	13.793	13.793	1.952	.083	.003,.118	7.065	1	157	.009**
コンテンツ	主体	2.297	2.297	1.952	.015	.000,.054	1.176	1	157	.280

【本調査②平均値の差の検定】

店員条件

水準ごとの平均値

水準	平均値	標準偏差	標準誤差	95%下限	95%上限	人数
協調	4.698	1.372	0.209	4.281	5.114	43
コンテンツ	4.615	1.290	0.207	4.204	5.026	39
等分散を仮定する場合の標準誤差 = 0.203						

差の検定							
検定の種類	差	標準誤差	95%下限	95%上限	*t* 値	df	*p* 値
Welch 検定	0.082	0.294	-0.505	0.669	0.280	79.890	.780
t 検定	0.082	0.295	-0.505	0.669	0.279	80	.781

効果量			
	効果量	95%下限	95%上限
相関係数 *r*	.031	-.187	.247
効果量 *d*	0.061	-0.368	0.491
Prep	.578		

AI 条件

水準ごとの平均値						
水準	平均値	標準偏差	標準誤差	95%下限	95%上限	人数
協調	3.865	1.636	0.269	3.329	4.400	37
コンテンツ	4.952	1.287	0.199	4.557	5.348	42
等分散を仮定する場合の標準誤差 = 0.240						

差の検定							
検定の種類	差	標準誤差	95%下限	95%上限	t 値	df	p 値
Welch 検定	-1.088	0.334	-1.745	-0.430	-3.253	68.168	.002
t 検定	-1.088	0.329	-1.743	-0.432	-3.303	77	.001

効果量			
	効果量	95%下限	95%上限
相関係数 *r*	-.352	-.532	-.142
効果量 *d*	-0.737	-1.190	-0.285
Prep	.989		

Ⅳ――――Study2

【本調査① 二要因混合計画の分散分析】

高関与群

水準ごとの平均値

		平均値	標準偏差	標準誤差	95%精度	人数
店員	協調	4.435	1.376	0.287	0.595	23
（n=40）	コンテンツ	4.941	1.391	0.337	0.715	17
AI	協調	4.000	1.789	0.390	0.814	21
（n=41）	コンテンツ	5.300	1.081	0.242	0.506	20

交互作用の検証

変数名	SS	MS	MSe	偏 η^2	95%CI	*F*値	df1	df2	*p*値
推薦主体	0.029	0.029	2.062	.000	.000, .032	0.014	1	77	.906
推薦根拠	16.322	16.322	2.062	.093	.008,.222	7.915	1	77	.006**
交互作用	3.150	3.150	2.062	.019	.000,.112	1.528	1	77	.220

【本調査① 二要因混合計画の分散分析】

低関与群

水準ごとの平均値

		平均値	標準偏差	標準誤差	95%精度	人数
店員	協調	5.000	1.338	0.299	0.626	20
（n=82）	コンテンツ	4.364	1.177	0.251	0.522	22
AI	協調	3.688	1.448	0.362	0.771	16
（n=76）	コンテンツ	4.636	1.399	0.298	0.620	22

交互作用の検証

変数名	SS	MS	MSe	偏 η^2	95%CI	*F*値	df1	df2	*p*値
推薦主体	5.315	5.315	1.784	.038	.000, .146	2.979	1	76	.088+
推薦根拠	0.480	0.480	1.784	.004	.000,.070	0.269	1	76	.605
交互作用	12.354	12.354	1.784	.083	.005,.211	6.923	1	76	.010*

単純主効果

スライス	変数名	SS	MS	MSe	偏 η2	95%CI	*F*値	df1	df2	*p*値
店員	根拠	15.312	15.312	1.784	.202	.010,.233	8.5581	1	76	.004**
AI	根拠	0.818	0.818	1.784	.011	.000,.080	0,459	1	76	.500

スライス	変数名	SS	MS	MSe	偏 η2	95%CI	*F*値	df1	df2	*p*値
協調	主体	4.242	4.242	1.784	.56	.000,.134	2.377	1	76	.127
コンテンツ	主体	8.340	8.340	1.784	.115	.000,.177	4.674	1	76	.034

【本調査②平均値の差の検定】

店員条件

水準ごとの平均値						
水準	平均値	標準偏差	標準誤差	95%下限	95%上限	人数
協調	5.000	1.338	0.299	4.395	5.605	20
コンテンツ	4.364	1.177	0.251	3.856	4.871	22
等分散を仮定する場合の標準誤差 = 0.281						

差の検定							
検定の種類	差	標準誤差	95%下限	95%上限	*t* 値	df	*p* 値
Welch 検定	0.636	0.390	-0.149	1.422	1.630	38.086	.111
t 検定	0.636	0.388	-0.148	1.421	1.640	40	.109

効果量			
	効果量	95%下限	95%上限
相関係数 *r*	.251	-.057	.516
効果量 *d*	0.497	-0.107	1.101
Prep	.873		

AI 条件

水準ごとの平均値						
水準	平均値	標準偏差	標準誤差	95%下限	95%上限	人数
協調	3.688	1.448	0.362	2.953	4.422	16
コンテンツ	4.636	1.399	0.298	4.032	5.241	22
等分散を仮定する場合の標準誤差 = 0.355						

差の検定							
検定の種類	差	標準誤差	95%下限	95%上限	t 値	df	p 値
Welch 検定	-0.949	0.469	-1.900	0.002	-2.023	31.810	.052
t 検定	-0.949	0.466	-1.895	-0.003	-2.035	36	.049

効果量			
	効果量	95%下限	95%上限

相関係数 *r*	-.321	-.581	-.002
効果量 *d*	-0.654	-1.303	-0.006
Prep	.921		

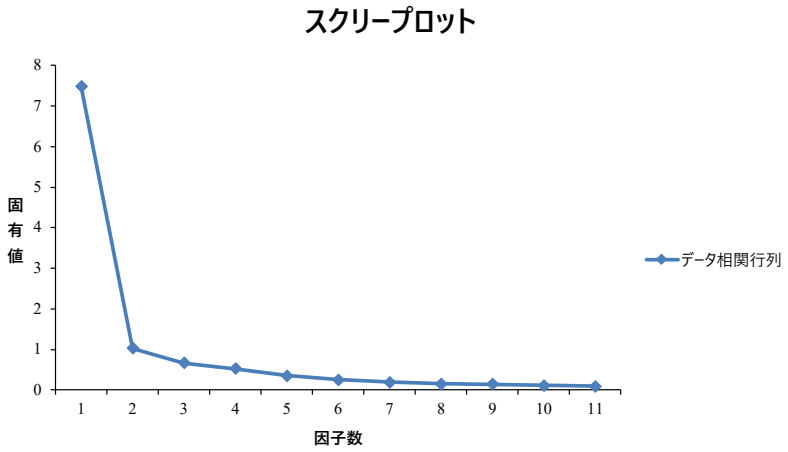
V————Study3

【本調査（1）　探索的因子分析】

記述統計			
項目	平均値	標準誤差	度数
提案にはスニーカーに関する十分な知識があると感じる	4.180	0.009	161
商品の良し悪しを適切に判断できる能力がある	4.286	0.009	161
提案者のアドバイスは頼りになると感じる	4.410	0.010	161
この提案の内容には専門的な説得力がある	3.969	0.010	161
客観的な事実に基づいていると感じる	4.547	0.009	161
偏りや無理な売り込みを感じない	4.702	0.009	161
公平・中立的な視点からのものだと感じる	4.602	0.009	161
論理的でデータに基づいていると思う	4.230	0.008	161
私の好みやニーズを理解していると感じる	4.081	0.010	161
この提案のおかげで自分に合った商品だと確信できた	4.261	0.010	161
提案された商品は個人にぴったり合うものだと感じる	4.174	0.010	161

	固有値	累積寄与	対角 SMC	MAP	Sum_h2
Factor1	7.479	67.990	7.250	.0790	7.250
Factor2	1.029	77.343	0.807	.0698	8.057
Factor3	0.666	83.395	0.416	.0887	8.473
Factor4	0.527	88.185	0.256	.0691	8.730
Factor5	0.357	91.427	0.119	.0927	8.848
Factor6	0.254	93.734	-0.002	.1299	---
Factor7	0.196	95.520	-0.036	.2049	---

Factor8	0.152	96.900	-0.066	.3087	---
Factor9	0.142	98.191	-0.091	.6002	---
Factor10	0.111	99.197	-0.106	1.0001	---
Factor11	0.088	100.000	-0.118	----	---



適合度			
乖離度 =	0.800	CFI =	.914
χ^2 値 =	123.391	RMSEA =	.131
DF =	34	AIC =	170.060
p =	.000	BIC =	234.770

因子相関行列		
	有能性因子	客観性因子
有能性因子	1.000	.721
客観性因子	.721	1.000

信頼性係数		
	有能性因子	客観性因子
α 係数	.952	.881
ω 係数	.954	.884

因子得点	.956	.916

逆転しない場合の信頼性係数		
	有能性因子	客観性因子
α係数	.952	.881
ω係数	.721	.884

項目	有能性因子	客観性因子	共通性
この提案のおかげで自分に合った商品だと確信できた	1.000	-.112	.851
提案された商品は個人にピッタリ合うものだと感じる	.907	-.018	.799
私の好みやニーズを理解していると感じる	.894	-.041	.748
提案者のアドバイスは頼りになると感じる	.822	.064	.756
提案にはスニーカーに関する十分な知識があると感じる	.683	.197	.699
この提案の内容には専門的な説得力がある	.660	.231	.710
商品の良し悪しを適切に判断できる能力がある	.508	.391	.698
倫理的でデータに基づいていると思う	-.133	.954	.745
公平・中立的な視点からのものだと感じる	.039	.846	.765
客観的な事実に基づいていると感じる	.117	.697	.618
偏りや無理な売り込みを感じない	.116	.632	.518

【本調査（2）　重回帰分析】

	SS	df	MS	*F*値	*p*値
モデル	190.548	5	38.110	49.497	.000
誤差	119.340	155	0.770		
全体	309.888	160			

適合指標	R^2	Adjust R^2	*F*値	df	*p*値	AIC	BIC	CAIC
	.615	.602	49.497	5, 155	.000	422.690	444.260	---

回帰係数（目的変数＝満足度）							
変数名	係数	標準誤差	95%下限	95%上限	*t*値	df	*p*値
切片	4.570	0.104	4.365	4.775	43.990	155	.000
有能性因子	0.859	0.224	0.416	1.302	3.832	155	.000
客観性因子	0.300	0.226	-0.146	0.746	1.328	155	.186

推薦主体	0.216	0.145	-0.070	0.503	1.492	155	.138
交互作用（有能性因子）	0.138	0.262	-0.380	0.657	0.527	155	.599
交互作用（客観性因子）	-0.128	0.265	-0.653	0.396	-0.483	155	.630

標準化係数（目的変数＝満足度）					
変数名	購買意向		95%下限	95%上限	VIF
有能性因子	.604	**	0.292	0.915	9.989
客観性因子	.206		-0.100	0.513	9.686
推薦主体	.078		-0.025	0.181	1.100
交互作用（有能性因子）	.069		-0.189	0.327	6.860
交互作用（客観性因子）	-.062		-0.316	0.192	6.641
R^2	.615	**			